

Mouhamed MBAYE

Ingénieur en traitement automatique des langues (TAL/NLP)

Montpellier, France (Mobile)

[Page Web](#) | [Mail](#) | +33 7 64 28 43 88

[LinkedIn](#) | [Hugging Face](#) | [GitHub](#)

PROFIL

Spécialisé en traitement automatique des langues (TAL) et membre actif de l'équipe NLP de [GalsenAI Lab](#), je suis passionné par la R&D en recherche et extraction d'information. Je mène des projets de recherche de bout en bout et dispose d'une expérience concrète sur des données non structurées, multilingues et à fort enjeu métier.

COMPÉTENCES TECHNIQUES

- . **Machine Learning & Deep Learning** : Python, PyTorch, Scikit-learn, Transformers, Fine-tuning
- . **IA Générative & LLMs** : RAG, IA Agentique, Prompt Engineering, vLLM, Ollama
- . **MLOps** : Docker, FastAPI, Flask, GCP, CI/CD, Git/GitHub, Streamlit
- . **Données & VDB** : ChromaDB, PostgreSQL (pgvector), SQL, MySQL, MongoDB, Neo4j, SPARQL/RDF
- . **R&D NLP** : SpaCy, NLTK, Unitex-GramLab, Label-Studio, Hugging Face, Overleaf

EXPÉRIENCES PROFESSIONNELLES

Ingénieur R&D NLP

2026 – Présent

GalsenAI Lab

- . Contribution à la recherche sur le TAL du wolof, à travers le développement et l'évaluation de LLM, la conception de jeux de données et la collaboration avec des chercheurs seniors.

Ingénieur NLP

Janvier – Juillet 2025

IMGT (IGH, CNRS), Montpellier

- . Conception et mise en production d'une solution d'extraction d'information à partir des textes scientifiques de l'OMS.

Data Scientist NLP

Janvier – Juin 2024

Université Mohammed V, Rabat

- . Modélisation et classification automatique de documents.

ARTICLES SCIENTIFIQUES

Août 2026

Article accepté à NL4AI 2026 : "Known but Unreachable : A Diagnostic Evaluation of Wolof Entity Linking against Wikidata".

Article de recherche sur l'évaluation diagnostique de l'*entity linking* wolof vers Wikidata, accepté pour publication dans les actes et pour une présentation orale à l'atelier **NL4AI 2026** (co-localisé avec AIXIA 2026 à Pérouse, Italie).

[PDF](#)

Mai 2026

Preprint : "MudawanSn : A Gold-Standard Wolof-Arabic Parallel Corpus for Machine Translation".

Prépublication co-écrite (avec Thierno Diop) présentant **MudawanSn**, une ressource de référence de **1 271** paires wolof-arabe traduites manuellement et alignées phrase à phrase. Évaluation comparative sur **NLLB-200**, **mT5** et **AfriNLLB**. L'article, le jeu de données et le code sont disponibles publiquement.

[PDF](#)

FORMATION

Master 2 Traitement automatique des langues (TAL NLP) Université Marie & Louis Pasteur, Besançon, France	Juin 2025
Master 2 Computational linguistics Université Mohammed V, Rabat, Maroc	Juin 2024

CERTIFICATIONS

Natural Language Processing with Probabilistic Models <i>DeepLearning.AI</i> – 2024 . Maîtrise des modèles probabilistes, incluant les N-grammes, l'étiquetage de séquences et les algorithmes d'auto-complétion.
Natural Language Processing with Classification and Vector Spaces <i>DeepLearning.AI</i> – 2024 . Techniques fondamentales du TAL : analyse de sentiment, espaces vectoriels et plongements de mots (<i>word embeddings</i>).
Retrieval Augmented Generation (RAG) <i>DeepLearning.AI</i> – 2025 . Conception, implémentation et déploiement de systèmes RAG complets et fiables, adaptés aux domaines d'application spécifiques.
Text Mining for Marketing <i>O.P. Jindal Global University</i> – 2025 . Acquisition des bases du <i>Text Mining</i> et identification des meilleures pratiques en analyse textuelle pour la prise de décision.
Elements of AI <i>University of Helsinki & MinnaLearn</i> – 2024 . Compréhension fondamentale des concepts de l'IA : machine learning, réseaux de neurones et implications sociétales.

LANGUES

Français : Courant
Anglais : Avancé
Arabe : Courant
Wolof : Maternelle