

# Mouhamed MBAYE

Ingénieur R&D NLP / TAL

Montpellier, France (Mobile)

[Page Web](#) | [Mail](#) | +33 7 64 28 43 88

[LinkedIn](#) | [Hugging Face](#) | [GitHub](#)

## PROFIL

Spécialisé en Traitement Automatique des Langues (TAL/NLP) et membre actif de l'équipe NLP de **GalsenAI Lab**, je suis passionné par la R&D en recherche et extraction d'information. Je mène des projets de recherche de bout en bout et dispose d'une expérience concrète sur des données non structurées, multilingues et à fort enjeu métier, de l'entraînement et du déploiement de modèles d'extraction à la construction d'un benchmark de liaison d'entités. Je souhaite poursuivre en thèse en TAL.

## EXPÉRIENCES

**Assistant de recherche en TAL (stage)** Oct. – Déc. 2026

**Laboratoire MoDyCo (UMR 7114, CNRS – Université Paris Nanterre)**

- Implémentation de l'algorithme AAD69 et comparaison avec des méthodes de sémantique distributionnelle.

**Ingénieur R&D NLP (bénévole)** 2026 – Présent

**GalsenAI Lab**

- Extension du tokenizer de SmolLM3.
- Continual pretraining (LoRA vs full fine-tuning).
- Supervised fine-tuning (SFT).

**Ingénieur NLP (stage)** Janv. – Juil. 2025

**IMGT (IGH, CNRS), Montpellier**

- Entraînement de modèles d'extraction d'information à partir des documents INN de l'OMS (anticorps monoclonaux).
- Déploiement des modèles : <https://www.imgt.org/nerapp/>

**Data Scientist-NLP (stage)** Janv. – Juin 2024

**Université Mohammed V, Rabat**

- Modélisation et classification automatique de documents.

## PUBLICATIONS ET COMMUNICATIONS

- **Known but Unreachable : A Diagnostic Evaluation of Wolof Entity Linking against Wikidata.** NL4AI 2026 (AIXIA, Pérouse), présentation orale. [\[PDF\]](#)
- **MudawanSn : A Gold-Standard Wolof–Arabic Parallel Corpus for Machine Translation.** Preprint, 2026. [\[PDF\]](#)
- **Connue mais introuvable.** Poster, ColDoc 2026 (à venir). [\[PDF\]](#)

## COMPÉTENCES TECHNIQUES

- **NLP et Outil :** Recherche et extraction d'informations/Text Mining (NER, entity linking, RAG), LLM (training tokenizer, continual pretraining, supervised fine-tuning, prompting), spaCy, NLTK, Label Studio, Hugging Face ressources et analyse linguistiques (annotation, benchmarking),
- **ML & DL :** Python, R PyTorch, Scikit-learn
- **MLOps :** Docker, FastAPI, Flask, GCP, CI/CD, Git/GitHub, Streamlit

## FORMATION

**Master 2 Sciences du langage – parcours ADiReO** 2026 – 2027 (en cours)

**Université Paul-Valéry Montpellier 3**

**Master 2 Traitement automatique des langues (TAL | NLP)** 2025

**Université Marie et Louis Pasteur, Besançon**

## LANGUES

**Français :** Courant | **Anglais :** Avancé | **Arabe :** Courant | **Wolof :** Langue maternelle